

LocusRL 项目管理文档

项目目标：在统一的跨博弈环境、对手池与预算协议下，系统比较 **LLM-as-Reward**、**LLM-as-Policy** 与 **Hybrid** 三种介入范式，并分析“博弈属性如何决定 LLM 的最优介入位置”。

Reward：LLM 生成密集奖励函数，训练传统神经网络策略。

Policy：LLM 自己作为策略，用真实比赛结果进行 GRPO/自博弈训练。

Hybrid：LLM 自己作为策略，但训练信号同时包含：

- 环境的真实终局收益；
- Reward 路线生成并审计过的密集过程奖励。

Hybrid 的科学价值是检验：Reward 和 Policy 究竟互补，还是会叠加偏差。它必须放在两条单独路线跑通以后，不能成为前期 blocker。

投稿策略：优先按照 **ICLR 2027** 推进；若 2026 年 8 月 31 日前未达到 ICLR 最低证据包，则主动切换至 **ICML 2027**，补足环境广度、随机种子、预算分析与 Hybrid 实验。

一、项目范围与优先级

P0：ICLR 必须完成

- ☐ 统一 `GameAdapter`、实验配置和结果记录规范
- ☐ 三个核心环境完整接入：Connect Four、Leduc Poker、Goofspiel
- ☐ Reward 与 Policy 两条主实验臂在三个环境上完整跑通
- ☐ Hybrid 至少在两个代表性环境上完成
- ☐ 至少完成 3 个随机种子的正式实验；关键结论补至 5 个随机种子
- ☐ 完成跨对手评估、样本效率与基础成本统计
- ☐ 形成至少一条有证据支持的“博弈属性 → 范式选择”结论
- ☐ 完成一版可投稿的论文、附录与复现说明

P1：ICLR 有余力再做，ICML 必须补全

- ☐ PettingZoo MPE Simple Tag 连续/高粒度动作环境
- ☐ 3B/4B 与 7B 模型规模消融
- ☐ 环境交互量、GPU 小时、货币成本三种等预算 Pareto 分析

- ☐ Reward hacking、均衡偏移、推理坍缩和奖励—策略共谋的完整诊断
- ☐ Zero-Shot Rule Transfer 与未见对手泛化

明确不做

- 不再维护任何旧领域专用环境、私有数据格式或人工标注链路
- 不在 ICLR 阶段扩张到超过四个正式环境
- 不为追求“实验数量”重复实现现有框架已有但与主问题无关的功能
- 不在核心实验完成前投入大量时间制作前端、展示系统或非论文交付物

二、组织结构与决策权

成员	核心角色	最终负责的交付物
栾承谕	项目负责人、方法论与故事线	方法冻结、实验问题、优先级、进度与论文总叙事
郭松言	Reward 主实验负责人	LLM 奖励生成、传统策略训练、Reward/Hybrid 奖励侧结果
辛博	Policy 主实验负责人	SFT、GRPO/StarPO、自博弈、Policy/Hybrid 策略侧结果
左宇翔	统一环境与评估基础设施负责人	GameAdapter、对手池、实验注册、评估接口与复现
顾宠	主笔与叙事整合	相关工作、论文骨架、实验结果写作、完整初稿
Yazdan	Baseline、扩展环境与量化分析	Baselines、Simple Tag、成本/迁移/图表分析
刘益丞	高级顾问与质量审查	方法审查、实验 sanity check、关键节点决策建议

决策规则

- **研究问题、项目范围、投稿与故事线：** 栾承谕最终决定。
- **Reward 实现细节：** 郭松言主导；涉及统一协议时与左宇翔对齐。
- **Policy 实现细节：** 辛博主导；涉及统一协议时与左宇翔对齐。
- **Hybrid：** 郭松言与辛博共同负责，不要单独修改公共评分协议。
- **论文表述：** 顾宠起草，栾承谕负责论点与 claim 审核，实验 owner 对数字负责。
- **重大技术争议：** 先形成一页 decision note，再由栾承谕组织讨论；必要时请益丞给出第三方意见。

三、个人任务与验收标准

栾承谕——项目负责人 + 方法论设计 + 故事线

☐ 冻结研究问题与三实验臂定义（7/16 前）

- ☐ 交付物：Reward、Policy、Hybrid 的输入、输出、训练信号与公平比较原则各一页。
- ☐ 验收：任何成员能用三分钟讲清三条实验臂区别，不再出现概念漂移。

☐ 冻结环境谱系与核心 claim（7/19 前）

- ☐ 核心环境：Connect Four、Leduc Poker、Goofspiel。
- ☐ 扩展环境：Simple Tag，仅在 P0 不受影响时推进。
- ☐ 验收：每个环境明确对应的属性轴和加入论文的必要性。

☐ 主持每周一次例会

固定议程：上周交付、当前 blocker、本周承诺、需要拍板的问题。
会后只保留 decision log 和 action items，不写冗长会议纪要。

☐ 维护项目总看板和风险清单（每周更新）

每个任务必须有 owner、deadline、验收物和状态。
连续 3 天无进展的 P0 blocker 必须升级处理。

☐ 论文故事线 v0/v1/v2（7/26、8/16、9/1）

- ☐ v0：研究问题与预期图表。
- ☐ v1：用初步实验修正 claim。
- ☐ v2：结果冻结后的最终故事线。

☐ 作者贡献记录与署名预案（8/31 前）

- ☐ 依据 CRediT 与实际交付记录形成预案。
- ☐ ICLR 2027 规则公布后，以官方摘要截止要求为准锁定作者名单。

☐ 投稿总审与最终提交

- ☐ 负责 claim 强度、实验闭环、匿名合规、OpenReview 信息与提交版本。

郭松言——Reward 主实验

☐ Reward 公共流水线跑通 (7/26 前)

- ☐ 输入：GameAdapter、规则与环境接口、训练统计。
- ☐ 输出：候选奖励代码、安全检查结果、传统策略 checkpoint、评估报告。
- ☐ 验收：在 Connect Four 上完成一次“生成→训练→反馈→迭代”闭环。

☐ Reward Baselines 完成 (8/5 前)

- ☐ Human-Crafted Reward
- ☐ Sparse Outcome Reward
- ☐ Potential-Based Shaping
- ☐ Eureka-Direct
- ☐ Random Reward Search
- ☐ 验收：所有 baseline 使用同一环境版本、种子表和对手池。

☐ 三核心环境 Reward 主实验 (8/18 前)

- ☐ 每个环境先 1 seed 调通，再批量 3 seeds。
- ☐ 交付：训练曲线、checkpoint、环境步数、GPU/API 成本、跨对手结果。

☐ Reward 安全与失效分析 (8/26 前)

- ☐ 定位 reward hacking、均衡偏移、固定对手过拟合案例。
- ☐ 至少沉淀 3 个可写入论文的成功/失败案例。

☐ Hybrid 奖励信号接口 (8/12 前)

- ☐ 将经过审计的 dense reward 与真实 outcome 组合成版本化评分接口。
- ☐ 与辛博共同完成 Hybrid smoke test 和权重/退火消融。

☐ 实验复核与附录材料 (9/5 前)

- ☐ 对论文中所有 Reward 数字签字确认，补齐 prompt、奖励代码与配置。

辛博——Policy 主实验

☐ Policy 训练栈与多轮环境接入 (7/23 前)

- ☐ 推荐优先复用 RAGEN/verl 等成熟框架，不自行重写完整训练器。
- ☐ 验收：在矩阵博弈或 Connect Four 上完成多轮 rollout 与一次参数更新。

☐ 统一文本接口与合法动作约束 (7/28 前)

- ☐ 输入使用 GameAdapter 的规范文本状态。
- ☐ 输出必须结构化解析；非法动作率应接近 0。
- ☐ **SFT 热启动与 Policy Baselines (8/5 前)**
 - ☐ Prompt-Only
 - ☐ SFT-Only
 - ☐ Outcome-Only GRPO
 - ☐ 参考轨迹由宇翔/Yazdan 提供，训练数据版本必须登记。
- ☐ **三核心环境 Policy 主实验 (8/18 前)**
 - ☐ 使用固定对手池 + 历史策略池，避免只对单一模型刷胜率。
 - ☐ 交付：checkpoint、rollout、训练曲线、非法动作率和跨对手评估。
- ☐ **Hybrid 主实验 (8/24 前)**
 - ☐ 接入松言提供的版本化奖励信号。
 - ☐ 比较 Outcome-only、Dense-only、Outcome+Dense、退火四种设置。
- ☐ **训练稳定性分析 (8/28 前)**
 - ☐ 检查零方差组、推理模板坍塌、策略循环、对手过拟合。
 - ☐ 与 Yazdan 共同输出诊断图和代表性轨迹。
- ☐ **实验复核与附录材料 (9/5 前)**
 - ☐ 对论文中所有 Policy/Hybrid 数字签字确认，补齐训练参数和 prompt。

左宇翔——统一环境 + 对手池 + 评估基础设施

- ☐ **仓库与实验规范初始化 (7/16 前)**
 - ☐ 推荐目录：adapters/、reward/、policy/、hybrid/、baselines/、eval/、configs/、artifacts/。
 - ☐ 建立统一配置模板、seed 表和实验命名规则。
- ☐ **GameAdapter v0.1 (7/23 前)**
 - ☐ 完成 Connect Four、Leduc Poker、Goofspiel。
 - ☐ 每个 adapter 提供数值状态、文本状态、合法动作、真实 outcome、可访问安全特征。
 - ☐ 验收：同一测试脚本能够切换三个环境并完成完整对局。
- ☐ **对手池与参考轨迹生成 (7/30 前)**
 - ☐ 包含 random、rule/search、CFR/MCTS/NFSP 或环境已有参考代理。
 - ☐ 导出带版本号的 SFT 轨迹和固定评估局面集。

☐ 统一评估器 v0.1 (8/5 前)

- ☐ 胜率、平均回报、Elo、跨对手矩阵。
- ☐ 可求解环境增加 exploitability/NashConv。
- ☐ 所有主实验只能通过统一评估器生成论文数字。

☐ 实验注册表与自动汇总 (8/12 前)

- ☐ 必填字段: commit、环境版本、模型/算法、seed、对手池、环境步数、GPU 小时、checkpoint、结果路径。
- ☐ 自动生成结果 CSV/JSON, 供 Yazdan 和顾宠使用。

☐ 复现检查 (8/30、9/8)

- ☐ 从空环境按 README 复现至少一组 Reward 和一组 Policy 实验。

顾宠——主笔 + 文献与叙事整合

☐ 论文骨架与 claim ledger (7/20 前)

- ☐ 建立 Introduction、Related Work、Method、Experiments、Limitations、Appendix 骨架。
- ☐ 每个 claim 标注所需证据、负责人和当前状态。

☐ 相关工作 v1 (7/30 前)

- ☐ 覆盖 Eureka/Text2Reward、RAGEN/SPIRAL/MARS/Strat-Reasoner、SPARK/RLAnything、OpenSpiel/PettingZoo。
- ☐ 区分已验证事实、我们的推断和待实验假设。

☐ 实验日志周更 (每周日)

- ☐ 从实验注册表同步有效结果、失败原因和待补表格。
- ☐ 不等实验全部结束才开始写作。

☐ 方法与实验设置初稿 (8/10 前)

- ☐ 由松言、辛博、宇翔逐段技术核验。

☐ 论文完整初稿 v1 (8/24 前)

- ☐ 允许结果表存在少量空格, 但论文必须能够从头读到尾。

☐ 结果版初稿 v2 (9/3 前)

- ☐ 填入正式实验, 完成主表、主图、消融和失败分析叙事。

☐ 终稿与附录 (内部截止日前)

- ☐ 统一术语、图注、引用、匿名化、复现说明和 limitations。

Yazdan——Baselines + 扩展环境 + 量化分析

☐ Baseline 复现清单与运行脚本（7/28 前）

- ☐ 协助宇翔跑通 search/solver reference 与传统 RL baseline。
- ☐ 验收：一条命令可在指定环境和 seed 上运行并登记结果。

☐ 成本统计模块（8/8 前）

- ☐ 自动记录环境交互量、训练耗时、GPU 型号/小时、峰值显存、LLM 调用量和推理延迟。

☐ 跨对手与规则迁移评估（8/22 前）

- ☐ 构造未见对手池和小规模规则变体。
- ☐ 输出性能保持率、最坏分位数表现与置信区间。

☐ Simple Tag 可行性试验（8/12 前给结论）

- ☐ 先做 adapter + baseline smoke test。
- ☐ 只有在不影响前三个核心环境时，才进入正式 Reward/Policy 实验。

☐ 统计分析与论文图表（8/30 前）

- ☐ 计算均值、标准差/置信区间、效应量。
- ☐ 生成胜率矩阵、学习曲线、成本 Pareto 图和属性—范式交互图。

☐ 与辛博共同完成 Policy Integrity 分析（8/28 前）

- ☐ 非法动作、模板坍塌、策略多样性和对手过拟合。

刘益丞——低频高级指导 + 质量审查

☐ 方法冻结审查（7/19 前，30–45 分钟）

重点看三实验臂是否公平、核心 claim 是否过强、环境选择是否能支撑结论。

☐ 中期实验审查（8/16 前后，30–45 分钟）

抽查一组 Reward 和一组 Policy 实验，判断是否存在明显方法漏洞或评价泄漏。

☐ Go/No-Go 审查（8/31，30 分钟）

对是否冲 ICLR 给出独立意见，但不承担日常推进责任。

☐ 终稿技术审查（9 月上旬，按需）

重点检查方法表述、实验结论和 reviewer 可能攻击的薄弱点。


☐ 全程按需技术指导

只升级高杠杆问题，不把日常调试和进度追踪压给益丞。

四、跨组依赖关系

上游交付	下游使用者	最迟时间	阻塞后处理
宇翔： GameAdapter v0.1	松言、辛博、 Yazdan	7月23日	先集中完成一个环境，不并行铺开
宇翔/Yazdan： 对手池与参考轨迹	松言、辛博	7月30日	使用简化 rule/random 完成 smoke test
松言：版本化 Reward 接口	辛博：Hybrid	8月12日	Hybrid 顺延，但不得阻塞 Policy 主实验
松言/辛博：主 实验结果	Yazdan：统计与 图表	持续，最晚 8/24	缺失实验先用占位表，明确 owner
全体实验 owner：结果核 验	顾宠：论文	每周日	未登记实验不得写入论文
顾宠：claim ledger	栾承谕、各 owner	7/20 起持续	没有证据的 claim 降级为假设


Hybrid 协作边界



五、ICLR 2027 进度表

截至本文件编写时，ICLR 2027 官方截稿日尚未发布。以下按上一届“9 月中下旬摘要、9 月下旬全文”的节奏倒排；官方日期公布后整体平移。内部截止必须早于官方截止至少 5–7 天。

阶段	时间	目标	退出条件
Phase 0: 范围冻结	7/13-7/19	方法、环境、接口、仓库和 claim 冻结	三实验臂定义完成，益丞审查通过
Phase 1: 最小闭环	7/20-8/2	一个环境跑通 Reward/Policy/Hybrid	Connect Four 三臂均能训练与评估
Phase 2: 核心扩展	8/3-8/16	Leduc + Goofspiel; baseline 与初步消融	三环境 Reward/Policy 1 seed 完成，至少两环境 3 seeds
Phase 3: 正式实验	8/17-8/30	Hybrid、正式 seeds、跨对手与成本分析	达到 ICLR 最低证据包
Gate: Go/No-Go	8月31日	决定 ICLR 或转 ICML	见下一节标准
Phase 4: 结果冻结	9/1-9/7	补关键实验、复核和图表	主表主图数字冻结
Phase 5: 论文冲刺	9/8-内部截止	终稿、附录、匿名检查、提交	至少提前官方全文截止 5-7 天完成



六、ICLR Go/No-Go 标准（8 月 31 日）

只有同时满足以下条件，才继续冲 ICLR：

- ☐ 三个核心环境均完成 Reward 与 Policy 正式实验
- ☐ Hybrid 至少完成两个环境，且不是只有 smoke test
- ☐ 至少 3 seeds；关键主结论有统计稳定性

- ☐ 统一对手池与跨对手结果完成，不只报告 self-play 胜率
- ☐ 至少一个环境可报告 exploitability/NashConv 或可靠近似
- ☐ 至少一条“属性 → 范式”的结论得到两个以上环境支持
- ☐ Reward、Policy、Hybrid 的成本数据可比较
- ☐ 论文完整初稿已经存在，而不是只写了提纲
- ☐ 没有尚未修复的数据泄漏、评估 bug 或不可复现的核心数字

直接转 ICML 的触发条件

- 到 8/16 仍未在一个环境上跑通三实验臂
- 到 8/24 仍只有单环境或单 seed 的主结果
- Hybrid 接口持续不稳定并反向阻塞 Reward/Policy
- 论文只能得出“某方法在某游戏胜率更高”，无法回答核心研究问题
- 关键成员因现实安排无法完成 9 月冲刺

转 ICML 不代表项目失败，而是主动把工作从“可投稿”扩展到“证据充分”。

七、ICML 2027 备选计划

ICML 2027 官方截稿日同样尚未发布。上一届在 1 月下旬提交摘要和全文，因此以下以 2027 年 1 月中旬内部冻结为规划基线。

如果 8/31 主动跳过 ICLR

- **9 月：** 修复三实验臂，完成全部核心环境 5 seeds。
- **10 月：** 完成 Simple Tag 连续环境与动作粒度实验。
- **11 月：** 完成 3B/4B vs. 7B、三类等预算曲线、规则迁移与跨对手泛化。
- **12 月：** 完成属性—范式选择器、完整失败分析和可复现开源包。
- **1 月上旬：** 结果冻结、外部预审和论文重写。
- **1 月中旬：** 内部全文截止；以官方 2027 日期为准提交。

如果已经投稿 ICLR

- 继续补实验和准备 rebuttal，但遵守 ICLR/ICML 当年官方双重投稿政策。
 - 待 ICLR 评审或决定明确后，再决定是回应、撤回改投还是扩展为后续版本。
 - 不在同一工作仍处于禁止双投状态时直接提交 ICML。
-

八、协作与实验管理规范

周例会

- 建议时间：每周一次，45 分钟。
- 每人只回答四件事：完成了什么、证据在哪里、卡在哪里、下周交付什么。
- 技术讨论超过 10 分钟仍无结论，转为小会并指定 decision owner。

异步更新

每周至少两次在项目群中用固定模板更新：

[Owner / 日期]

完成：

结果链接：

Blocker：

下一交付（含日期）：

需要谁决定/协助：

实验登记最低要求

任何进入论文的实验必须能够回答：

1. 使用哪个 commit 和配置？
2. 环境与对手池版本是什么？
3. 使用哪些随机种子？
4. 训练环境步数、GPU 时间和模型调用量是多少？
5. checkpoint、日志和结果文件在哪里？
6. 谁运行、谁复核？

代码审查

- 公共接口、评估器和论文数字生成脚本必须至少一人 review。
- Reward 与 Policy 私有训练代码由各 owner 负责，但不得绕开公共评估器。
- 不允许人工复制粘贴论文数字；所有主表应由结果文件自动生成。

九、风险清单

风险	早期信号	应对措施	Owner
范围过大	四个环境同时半成品	P0 只保三个环境，Simple Tag 降为 P1	栾承谕
GameAdapter 阻塞	7/23 仍无法统一跑一局	全员先集中 Connect Four；接口先最小化	宇翔
Reward 训练成本爆炸	每个候选都需长时间训练	低保真筛选→少量候选正式训练	松言
Policy 无有效探索	Prompt/SFT 成功率接近 0	简化环境、SFT 热启动、课程与固定对手	辛博
Hybrid 共谋	代理奖励升高但 outcome 下降	outcome anchor、奖励退火、独立评估	松言/辛博
比较不公平	双方各用有利预算口径	同时报告三类预算和 Pareto 前沿	Yazdan
写作滞后	8 月仍只有提纲	7 月建骨架，结果随实验周更	顾宠
顾问时间有限	日常问题不断升级给益丞	只在三个里程碑集中审查	栾承谕
核心数字不可复现	相同配置结果无法重跑	统一注册、版本、seed 与复现检查	宇翔
ICLR 时间不足	8/24 仍无完整证据包	8/31 主动转 ICML，不低质量硬赶	全体

十、关键节点总览

- 7/16：方法、仓库和实验规范初步冻结
- 7/23：GameAdapter v0.1；Policy 训练栈跑通
- 8/2：单环境 Reward/Policy/Hybrid 最小闭环
- 8/16：三核心环境初步结果；中期方法审查
- 8/24：Reward/Policy 主实验与论文 v1 完成
- 8/31：ICLR Go/No-Go；作者贡献预案
- 9/7：ICLR 路线结果冻结
- 官方摘要截止前：作者名单与真实摘要锁定

- **官方全文截止前 5-7 天：** 内部终稿与匿名检查完成

十一、个人管理文档链接

(这个位置放大家的管理文档)

Yazdan: [📖 Yazdan Project Management Document](#)

左宇翔: [📖 左宇翔的RL双范式项目管理](#)